

**«Санкт-Петербургский государственный электротехнический университет
«ЛЭТИ» им. В.И.Ульянова (Ленина)»
(СПбГЭТУ «ЛЭТИ»)**

Направление	01.03.02 Прикладная математика и информатика
Профиль	Математическое обеспечение программно-информационных систем
Факультет	КТИ
Кафедра	МО ЭВМ

К защите допустить

Зав. кафедрой

А.А. Лисс

**ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
БАКАЛАВРА**

**Тема: НЕЙРОННАЯ СЕТЬ ДЛЯ ПРОГНОЗИРОВАНИЯ РИСКА
ЗАБОЛЕВАНИЙ НА ОСНОВЕ МНОГОМЕРНЫХ ДАННЫХ**

Студент			Е.Д. Мордасов
		<i>подпись</i>	
Руководитель	К.Т.Н., доцент		К.А. Борисенко
	<i>(Уч. степень, уч. звание)</i>	<i>подпись</i>	
Консультанты			А.А. Трусов
		<i>подпись</i>	
	К.Т.Н., доцент		М.М. Заславский
		<i>подпись</i>	

Санкт-Петербург

2026

ЗАДАНИЕ НА ВЫПУСКНУЮ КВАЛИФИКАЦИОННУЮ РАБОТУ

Утверждаю
Зав. кафедрой МО ЭВМ
_____ А.А. Лисс
«___» _____ 2026 г.

Студент Мордасов Е.Д. Группа 2383

Тема работы: Нейронная сеть для прогнозирования риска заболеваний на основе многомерных данных.

Место выполнения ВКР: Санкт-Петербургский государственный электротехнический университет «ЛЭТИ» им. В.И. Ульянова (Ленина)

Исходные данные (технические требования):

Необходимо разработать нейронную сеть для прогнозирования риска заболеваний.

Содержание ВКР:

Введение, Обзор предметной области, Формулировка требований к отбору и постановка задачи, Описание метода решения, Заключение

Перечень отчетных материалов: пояснительная записка, иллюстративный материал

Дополнительные разделы:

Дата выдачи задания
«6» апреля 2026 г.

Дата представления ВКР к защите
«16» июня 2026 г.

Студент

Руководитель

к.т.н., доцент
(Уч. степень, уч. звание)

Е.Д. Мордасов

К.А. Борисенко

КАЛЕНДАРНЫЙ ПЛАН ВЫПОЛНЕНИЯ ВЫПУСКНОЙ КВАЛИФИКАЦИОННОЙ РАБОТЫ

Утверждаю
Зав. кафедрой МО ЭВМ
_____ А.А. Лисс
« ____ » _____ 20 ____ г.

Студент Мордасов Е.Д. Группа 2383
Тема работы: Нейронная сеть для прогнозирования риска заболеваний на
основе многомерных данных.

№ п/п	Наименование работ	Срок выполнения
1	Обзор литературы по теме работы	10.02 – 20.02
2	Обзор предметной области	21.02 – 05.03
3	Формулировка требований к решению и постановка задачи	06.03 – 07.03
4	Разработка математической модели	08.03 – 18.04
5	Разработка архитектуры решения	19.04 – 10.05
6	Реализация программы	11.05 – 25.05
7	Предзащита	26.05 – 27.05

Студент _____ Е.Д. Мордасов
Руководитель к.т.н., доцент _____ К.А. Борисенко
(Уч. степень, уч. звание)

РЕФЕРАТ

Пояснительная записка 54 стр., 12 рис., 7 табл., 17 ист.

ПРОГНОЗИРОВАНИЕ РИСКА ЗАБОЛЕВАНИЙ, НЕЙРОННЫЕ СЕТИ,
МНОГОМЕРНЫЕ КЛИНИЧЕСКИЕ ДАННЫЕ,
ИНТЕРПРЕТИРУЕМОСТЬ, SHAP.

Объектом исследования процесс прогнозирования риска развития заболеваний на основе многомерных медицинских данных пациентов.

Предметом исследования является уровень точности прогнозирования риска заболевания, достигаемый с помощью нейросетевых моделей.

Цель работы: разработать нейросетевую модель для прогнозирования риска заболеваний на основе многомерных клинических данных.

Практическая значимость работы: В данной выпускной квалификационной работе изучаются подходы к классификации пациентов с использованием алгоритмов глубокого обучения. Проведено исследование различных парадигм машинного обучения: градиентного бустинга, рекуррентных и полносвязных нейронных сетей.

Установлено, что глубокая полносвязная нейронная сеть DNN, оптимизированная по метрике PR-AUC с последующим подбором порога классификации по F2-score, является наиболее эффективным методом при сильном дисбалансе классов. Применение алгоритмического взвешивания классов и архитектуры с расширением признакового пространства до 224 нейронов в скрытом слое позволило достичь полноты выявления больных Recall на уровне 84% при параметре ROC-AUC 0.83. Внедрен SHAP, объясняющий влияние симптомов на итоговый диагноз.

ABSTRACT

In this thesis, we study approaches to patient classification using deep learning algorithms. We investigate various machine learning paradigms, including gradient boosting, recurrent neural networks, and fully connected neural networks.

We find that a deep fully connected neural network DNN optimized using the PR-AUC metric, followed by calibration of the classification threshold using the F2-score, is the most effective screening method for highly imbalanced classes. The use of algorithmic weighting of classes and architecture with the expansion of the feature space up to 224 neurons in the hidden layer made it possible to achieve the completeness of patient detection Recall at the level of 84% with a ROC-AUC parameter of 0.83. A SHAP has been implemented to explain the effect of symptoms on the final diagnosis. A real-time disease risk assessment program has been developed

СОДЕРЖАНИЕ

ОПРЕДЕЛЕНИЯ, ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ	7
ВВЕДЕНИЕ.....	9
1 ОБЗОР ПРЕДМЕТНОЙ ОБЛАСТИ	11
1.1 ПРИНЦИП ОТБОРА АНАЛОГОВ.....	11
1.2 КРИТЕРИИ СРАВНЕНИЯ АНАЛОГОВ	11
1.3. КРИТЕРИИ ПОДБОРА МЕТРИК	14
1.4 ТАБЛИЦА СРАВНЕНИЯ АНАЛОГОВ	15
1.5 ВЫВОДЫ ПО ИТОГАМ СРАВНЕНИЯ	16
2 ВЫБОР И ОБОСНОВАНИЕ МЕТОДА РЕШЕНИЯ.....	18
2.1 АРХИТЕКТУРА РЕШЕНИЯ.....	18
2.2 КАЧЕСТВА РЕШЕНИЯ.....	20
2.3 МЕТОДОЛОГИЯ ВАЛИДАЦИИ.....	21
3 ОПИСАНИЕ МЕТОДА РЕШЕНИЯ	22
3.1 АРХИТЕКТУРНЫЕ ПРИНЦИПЫ	22
3.2 ОЖИДАЕМЫЕ РЕЗУЛЬТАТЫ	23
4 РЕАЛИЗАЦИЯ МЕТОДА РЕШЕНИЯ	25
4.1 АВТОМАТИЗИРОВАННЫЙ ПОДБОР ПАРАМЕТРОВ НЕЙРОННОЙ СЕТИ.....	25
4.2 ФИНАЛЬНОЕ ОБУЧЕНИЕ МОДЕЛЕЙ.....	28
4.3 ПОДБОР ПОРОГА КЛАССИФИКАЦИИ.....	30
4.4 ОЦЕНКА ПРОИЗВОДИТЕЛЬНОСТИ НА ТЕСТОВОЙ ВЫБОРКЕ	34
4.5 ИНТЕРПРЕТАЦИЯ С ПОМОЩЬЮ SHAP	37
5 БЕЗОПАСНОСТЬ ЖИЗНЕДЕЯТЕЛЬНОСТИ	43
5.1 ОБЩАЯ ХАРАКТЕРИСТИКА УСЛОВИЙ ПРИМЕНЕНИЯ.....	43
5.2 АНАЛИЗ ОПАСНОСТЕЙ	43
5.3 ОБЕСПЕЧЕНИЕ ДОПУСТИМОГО РИСКА РАЗРАБОТКИ	45
ЗАКЛЮЧЕНИЕ	50
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ.....	52

ОПРЕДЕЛЕНИЯ, ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ

AUC-ROC (Area Under the Receiver Operating Characteristic Curve) - площадь под ROC-кривой, стандартная метрика для оценки классификации при дисбалансе классов в медицинском машинном обучении.

PR-AUC (Precision-Recall AUC) - метрика оценки качества модели в задачах бинарной и многоклассовой классификации. Эта метрика представляет собой площадь под кривой Precision-Recall (кривой точности и полноты).

SHAP (SHapley Additive exPlanations) - метод объяснения предсказаний моделей машинного обучения на основе теории кооперативных игр и обеспечивающий локальные и глобальные объяснения.

LIME (Local Interpretable Model-agnostic Explanations) - техника создания локально интерпретируемых приближений для объяснения отдельных предсказаний модели.

DNN (Deep Neural Network) - глубокая полносвязная нейронная сеть с несколькими слоями нейронов и функциями активации.

LSTM (Long Short-Term Memory) - рекуррентная нейронная сеть для обработки последовательностей и временных зависимостей в данных.

GBDT (Gradient Boosting Decision Trees) - группа методов ансамблей, включающих XGBoost, CatBoost и LightGBM. Они итеративно строят деревья решений.

SMOTE (Synthetic Minority Over-sampling Technique) - техника синтеза примеров меньшего класса для решения проблемы дисбаланса классов.

Batch Normalization - способ нормализации активаций нейронной сети для стабилизации и ускорения обучения.

Dropout - техника регуляризации, которая случайно удаляет нейроны во время обучения, чтобы избежать переобучения.

ROC-кривая (Receiver Operating Characteristic) - кривая, показывающая связь между долей правильно классифицированных положительных примеров и долей неправильно классифицированных отрицательных примеров.

Дисбаланс классов - ситуация, когда распределение примеров по классам значительно неравномерно, например, 70% здоровых и 30% больных.

Интерпретируемость – способность модели предоставлять понятные человеку объяснения своих решений.

Предсказательная способность - характеристика модели, отражающая её способность точно предсказывать будущие результаты на новых данных.

ВВЕДЕНИЕ

Объектом исследования процесс прогнозирования риска развития заболеваний на основе многомерных медицинских данных пациентов.

Предметом исследования является уровень точности прогнозирования риска заболевания, достигаемый с помощью нейросетевых моделей.

Цель работы: разработать нейросетевую модель для прогнозирования риска заболеваний на основе многомерных клинических данных.

Своевременное и точное прогнозирование риска заболеваний является критической задачей современной системы здравоохранения, позволяя организовать эффективные профилактические мероприятия и оптимизировать использование ресурсов. Постановка диагноза пациенту требует проведения особых тестов. Это сильно замедляет процесс проверки населения. Традиционные методы оценки риска часто ограничены в способности выявлять сложные нелинейные взаимодействия между множеством клинических сложных факторов. Однако современные методы на основе нейронных сетей демонстрируют огромный потенциал в борьбе с этими ограничениями. Например, для прогнозирования коронарной болезни сердца специализированные нейросетевые архитектуры увеличивают AUC-ROC с 0.806 до 0.942, это соответствует приросту более чем на 16.9% [1]. Модели на основе искусственного интеллекта демонстрируют рост AUC до 0.818 против 0.732 для оценки сердечно-сосудистого риска [1].

Высока точность достигается за счёт способности нейронных сетей выявлять скрытые паттерны во множестве разных признаков от демографических характеристик и результатов лабораторных тестов до генетических маркеров. Однако одной из ключевых проблем при внедрении таких систем в клиническую практику является интерпретируемость получаемых прогнозов. Врачи и регуляторные органы требуют понимания того, на основе каких конкретных клинических факторов модель выносит свой вердикт. Это делает актуальной разработку гибридных подходов, которые сочетают высокую предсказательную точность с объяснимостью решений.

Для достижения поставленной цели необходимо решить следующие задачи:

1. Провести обзор существующих подходов и аналогов в области машинного обучения для медицинского прогнозирования.
2. Спроектировать архитектуру глубокой полносвязной нейронной сети, устойчивую к дисбалансу данных.
3. Сделать модуль обучения модели и автоматического подбора оптимальных гиперпараметров.
4. Разработать алгоритм динамического подбора порога классификации для минимизации пропуска больных пациентов.
5. Интегрировать систему объяснения решений SHAP для интерпретации результатов работы нейросети.

1 Обзор предметной области

1.1 Принцип отбора аналогов

Процесс отбора аналогов произведен через поиск по специальным системам научных публикаций, такие как Google Scholar, PubMed, arXiv [1]. И платформе GitHub для нахождения решений с открытым исходным кодом [2].

Использованные поисковые запросы: "neural network disease risk prediction", "deep learning cardiovascular disease classification", "XGBoost CatBoost medical diagnosis tabular data", "LSTM RNN healthcare prediction", "gradient boosting disease risk", "class imbalance medical prediction SMOTE", "explainable AI SHAP LIME healthcare".

В результате выбраны пять аналогов, представляющих основные парадигмы современного подхода к прогнозированию риска заболеваний:

- Ансамбли алгоритмов бустинга XGBoost, CatBoost, LightGBM.
- Глубокие нейронные сети общего назначения (DNN/MLP).
- Рекуррентные нейронные сети.
- Гибридные ансамбли с техниками интерпретируемости (GBDT + SHAP/LIME).
- Трансформер-подобные архитектуры для табличных данных (SAINT/TabTransformer).

Выбор этих аналогов объясняется необходимостью анализа различных подходов к обработке многомерных клинических данных. И их способности достичь целевого показателя AUC-ROC и обеспечить интерпретируемость результатов

1.2 Критерии сравнения аналогов

1.2.1 Ансамбли бустинга XGBoost, CatBoost, LightGBM

Алгоритмы градиентного бустинга деревьев GBDT представляют собой популярное семейство методов машинного обучения. Они итеративно строят ансамбли деревьев решений, где каждое новое дерево минимизирует ошибки предыдущих моделей. Программные реализации XGBoost, CatBoost и

LightGBM максимально оптимизированы для эффективной работы со структурированными табличными данными.

Ключевым преимуществом этих алгоритмов является качественная встроенная обработка категориальных переменных [3]. Наиболее эффективно данный механизм реализован в библиотеке CatBoost. Также эти методы успешно справляются со случайными пропущенными значениями и сильным дисбалансом классов без привлечения сторонних инструментов предобработки. Различные медицинские исследования показывают стабильное достижение метрики AUC-ROC в высоком диапазоне от 0.85 до 0.97 при прогнозировании сердечно-сосудистых заболеваний.

Однако у бустинга есть и серьезные недостатки. Модели требуют долгого и ресурсоемкого подбора многочисленных гиперпараметров. Главный минус заключается в относительно низкой встроенной интерпретируемости. Без применения специализированных внешних техник типа SHAP практикующий врач не может понять внутреннюю логику принятия решений.

1.2.2 Полносвязные нейронные сети DNN/MLP

Данный класс архитектур строится на базе последовательных слоев с нелинейными функциями активации ReLU. Для стабилизации обучения в них обязательно используются слои пакетной нормализации Batch Normalization и слои исключения нейронов Dropout. Подобные глубокие сети позволяют успешно моделировать сложные скрытые взаимосвязи между разнородными клиническими признаками.

При правильной и точной настройке внутренних параметров полносвязные нейросети позволяют достигать высоких показателей предсказательной способности [3,4,5]. Метрика AUC-ROC для них обычно находится в стабильном диапазоне от 0.88 до 0.94. При этом модели имеют ряд критических ограничений. Они требуют огромных объемов структурированных медицинских данных для качественного обучения. Такие сети крайне чувствительны к предварительному масштабированию входных признаков. Наконец, они обладают классической проблемой «черного ящика».

Нейросеть выдает точный результат, но принципиально неспособна объяснить логику своего вердикта без внешних методов интерпретации.

1.2.3 Рекуррентные нейронные сети LSTM

Архитектуры на базе блоков долгой краткосрочной памяти (LSTM) изначально проектировались для работы со сложными последовательностями данных. Они способны эффективно моделировать различные временные зависимости и долгосрочные тренды. При наличии динамической временной информации эти модели показывают отличные результаты. Это актуально для последовательностей регулярных визитов к врачу или для анализа многолетней истории болезни пациента. В таких специфических задачах они обеспечивают показатель F1-score на уровне от 0.88 до 0.91 [6,7].

Главный недостаток архитектуры проявляется при работе со статическим сценарием медицинского прогнозирования. Если временная структура в анкетах пациентов полностью отсутствует, преимущества алгоритмов LSTM становятся минимальными. При этом вычислительная сложность и требования к памяти у рекуррентных сетей остаются значительно выше, чем у альтернативных подходов. По этой причине их применение для статичных табличных данных нецелесообразно.

1.2.4 Гибридные ансамбли с методами интерпретируемости GBDT + SHAP/LIME

Комбинированный подход, который объединяет ансамбли XGBoost, CatBoost, Random Forest с техниками объяснения SHAP и LIME [8,9,10]. SHAP вычисляет вклад каждого признака на основе теории кооперативных игр, обеспечивая глобальные и локальные объяснения. Сохраняет высокую точность AUC-ROC 0.85-0.97 и добавляет критически важную интерпретируемость для клинической практики. Недостаток в вычислительной сложности SHAP на больших датасетах.

1.2.5 Трансформер-подобные архитектуры SAINT/TabTransformer

Адаптируют механизм самовнимания из трансформеров для табличных данных. SAINT применяет двухуровневое внимание внутри признаков и

между образцами, TabTransformer объединяет embedding-слои с трансформерной архитектурой. Показывает конкурентоспособность с GBDT на уровне 0.85–0.92 и обеспечивает встроенную интерпретируемость через веса внимания [11,12]. Недостатки требуют больше данных, на практике часто уступают GBDT на среднего размера датасетах, требуют GPU.

1.3. Критерии подбора метрик

Выбор ключевых критериев обусловлен необходимостью решения серьезных проблем. Разработанная архитектура должна обеспечить:

1. Высокую предсказательную способность
2. Обработку реальных медицинских данных с дисбалансом классов, пропущенными значениями или смешанными типами признаков
3. Интерпретируемость результатов для врачей

Критерий 1: точность AUC-ROC. Площадь под ROC-кривой является основой медицинского машинного обучения для оценки классификации при дисбалансе классов. Вместо традиционной метрики ROC-AUC, которая может давать ложнооптимистичные оценки за счет огромного числа правильно угаданных здоровых людей, выбрана метрика PR-AUC (Precision-Recall AUC). Для подбора подходящего порога активации используется метрика F2-Score, которая придает полноте нахождения больных в два раза больший вес, чем точности.

Критерий 2: обработка табличных медицинских данных. Оценивается как качественно алгоритм справляется с категориальными переменными, пропущенными значениями и с дисбалансом классов без предварительной обработки. Измеряется описанием встроенных механизмов: какие стратегии используются для категориальных переменных, как обрабатываются NaN-значения, какие встроенные техники применяются к дисбалансу.

Критерий 3: интерпретируемость и поддержка объяснения прогнозов. Измеряется способность алгоритма предоставить объяснения решений. Включает встроенную интерпретируемость, т.е. способность модели

напрямую объяснить решение, совместимость с методами объяснения SHAP, типы возможных объяснений глобальные и локальные.

1.4 Таблица сравнения аналогов

Для обеспечения объективности сравнительного анализа, оценки по критериям основаны на следующих шкалах, привязанных к требованиям прогнозирования риска заболеваний, таблица 1, таблица 2, таблица 3.

Таблица 1 – Шкала оценки критерия "Прогностическая точность (AUC-ROC)"

Шкала	Обоснование
Высокая - 2	$AUC-ROC \geq 0.94$ (превосходная способность различать классы при дисбалансе)
Средняя - 1	$AUC-ROC 0.88-0.93$ (средняя способность различать классы, соответствует большинству задач)
Низкая - 0	$AUC-ROC < 0.88$ (недостаточная точность для медицинских приложений)

Таблица 2 – Шкала оценки критерия "Обработка табличных медицинских данных"

Шкала	Обоснование
Высокая - 2	Встроенная обработка категориальных переменных, пропусков и дисбаланса (GBDT/CatBoost)
Средняя - 1	Требует предварительной обработки 1–2 типов данных (DNN, трансформеры)
Низкая - 0	Требует полной предварительной обработки всех типов данных (LSTM)

Таблица 3 – Шкала оценки критерия "Интерпретируемость"

Шкала	Обоснование
Высокая - 2	Встроенная интерпретируемость + полная совместимость SHAP/LIME (GBDT+SHAP, трансформеры)

Продолжение таблицы 3

Средняя - 1	Полная совместимость SHAP/LIME без встроенной интерпретируемости (DNN, LSTM)
Низкая - 0	Ограниченная совместимость или высокая вычислительная сложность объяснений

Таблица 4 – Сравнение аналогов по ключевым техническим критериям

Аналог	Прогностическая точность	Обработка табличных данных	Интерпретируемость
GBDT (XGBoost/CatBoost)	2	2	1
DNN/MLP	1	1	1
LSTM	0	0	1
GBDT+SHAP/LIME	2	2	2
SAINT/TabTransformer	1	1	2

1.5 Выводы по итогам сравнения

Анализ на основе таблица 4 выявил следующие ключевые факторы:

1. GBDT демонстрируют наиболее сбалансированный профиль для задачи. Они достигают целевой AUC-ROC (0.90–0.97), имеют встроенную обработку всех типов медицинских данных и требуют минимум предварительной обработки.

2. DNN достигают сравнимую точность (0.88–0.94) но требуют значительно большей подготовки. Кодирование признаков, явное решение дисбаланса SMOTE, class weights, тщательная регуляризация. Разумны при наличии времени на подбор гиперпараметров.

3. LSTM показывают более низкую точность при отсутствии временной структуры. На статических данных пропадает преимущество перед DNN и GBDT при аналогичных требованиях по памяти.

4. Гибридные ансамбли GBDT + SHAP/LIME сохраняют точность базовой модели и добавляют интерпретируемость важную для клинических приложений. Внешние валидации показывают стабильную работу на новых данных.

5. Трансформер-подобные архитектуры - перспективный, но менее состоятельный подход. На среднего размера датасетах часто уступают GBDT, требуют GPU, требуют больше данных и исследований.

Заключение обзора. Для решения задачи выбран гибридный подход - разработка оптимизированной полносвязной нейронной сети с последующим применением алгоритмов SHAP для обеспечения интерпретируемости.

2 Выбор и обоснование метода решения

2.1 Архитектура решения

На основе проведенного в первой главе анализа существующих подходов, для решения поставленной задачи выбрана архитектура, которая включает в себе глубокую нейронную сеть (DNN) и методы интерпретации. Проектируемая система представляет собой последовательность, состоящую из трех основных функциональных блоков: модуль предобработки, нейросетевой классификатор и модуль интерпретируемости и принятия решений.

2.1.1 Входной модуль обработки данных

В качестве исходной базы данных используется набор BRFSS 2015, содержащий 21 независимый клинический признак. Поскольку медицинские данные часто характеризуются пропусками и разным масштабом величин, система обработки данных должна решать следующие задачи:

Восстановление пропущенных значений в анкетах с использованием стратегии среднего mean. Это позволяет сохранить размерность выборки без потери значимых паттернов.

Приведение всех векторов к единому масштабу с помощью StandardScaler. Это необходимо для обеспечения стабильной работы градиентных методов оптимизации, так как нейросеть чувствительна к признакам с большой амплитудой, например, возраст или индекс массы тела.

Балансировка классов. учитывая, что диабет является редким событием, примерно в 14% случаев, в системе планируется использовать метод алгоритмического взвешивания классов (class_weight). В отличие от синтетической генерации примеров SMOTE, class_weight позволяет модели обучаться на реальном распределении признаков. Он искусственно повышает штраф за ошибку на классе больных пациентов.

2.1.2 Входной модуль обработки данных

Выбор структуры обусловлен необходимостью извлечения признаков при сохранении вычислительной эффективности.

Планируемая топология сети включает:

Входной слой, размерность 21 нейрон по количеству входных признаков

Скрытые слои, 4 последовательных блока Dense-нейронов с функцией активации ReLU.

Архитектура предполагает расширение признакового пространства на начальном этапе до 256 нейронов для поиска зависимостей в данных и последующее сжатие для формирования финального вывода.

Регуляризация. для предотвращения переобучения в модель интегрируются слои пакетной нормализации BatchNormalization и слои исключения нейронов Dropout)с коэффициентом до 0.5.

Выходной слой. 1 нейрон с сигмоидной функцией активации для получения непрерывной оценки вероятности заболевания в диапазоне от [0; 1].

2.1.3 Модуль интерпретируемости

Одной из ключевых проблем внедрения нейросетей в клиническую практику является понятие черного ящика. Для преодоления этой проблемы в разработку закладывается модуль интерпретации на основе библиотеки SHAP. Планируется использование метода DeepExplainer, который на основе теории кооперативных игр будет разбивать итоговую вероятность на вклад каждого из 21 симптомов. Так же проектируется модуль подбора порога классификации. Вместо стандартных значений порога 0.5 планируется реализовать алгоритм математического подбора порога, максимизирующий метрику F2-score. Это обеспечит приоритет полноты нахождения больных над точностью, что является одним из самых важных требований для системы первичного скрининга.

2.2 Качества решения

Разрабатываемое программное решение должно строго соответствовать ряду важных технических и клинических критериев. В первую очередь модель должна демонстрировать высокую предсказательную способность на несбалансированных медицинских выборках. Целевым ориентиром для системы является достижение устойчивого показателя ROC-AUC на уровне не менее 0.82–0.83. При этом приоритетным требованием выступает высокая клиническая чувствительность алгоритма. Модель обязана обеспечивать полноту выявления больных пациентов (Recall) на уровне не менее 80%. Такой подход позволит минимизировать опасные ложноотрицательные прогнозы при проведении первичного скрининга населения.

Важным клиническим качеством решения является интерпретируемость полученных результатов. Программа не должна работать по принципу «черного ящика». Проектируемая архитектура предполагает наглядную визуализацию внутренней логики принятия решений нейросетью. Это необходимо для формирования доверия со стороны медицинских специалистов, которые смогут видеть обоснование каждого вердикта.

Также к системе предъявляются жесткие требования в плане оперативности. Время генерации индивидуального прогноза риска для одного пациента не должно превышать 100 мс. Данная скорость обработки данных необходима для успешной интеграции программного модуля в информационные системы медицинских учреждений и его работы в режиме реального времени. Наконец, решение должно обладать высокой устойчивостью к естественному шуму в анкетных данных. Для этого в структуру нейросети внедряются надежные механизмы регуляризации, которые предотвратят переобучение алгоритма на случайных искажениях.

2.3 Методология валидации

Для объективной и обоснованной оценки качества проектируемой архитектуры глубокой нейронной сети применяется классическая стратегия разбиения исходных данных. Весь доступный массив информации делится на три независимые группы. На обучающую выборку выделяется 70% от общего объема данных. На валидационную и независимую тестовую группу отводится по 15% данных соответственно. Разделение выполняется с применением стратификации для сохранения исходного дисбаланса классов в каждом подмножестве. Процесс сквозной валидации данных включает в себя несколько последовательных и обязательных этапов. Первым этапом является автоматический поиск оптимальных гиперпараметров модели. Для нахождения наилучшей конфигурации слоев нейросети и скорости обучения применяются алгоритмы KerasTuner и метод Hyperband. Это позволяет быстро протестировать сотни различных архитектурных вариантов. Вторым этапом выступает непрерывный мониторинг процесса обучения нейронной сети. Система осуществляет детальное отслеживание метрик `val_pr_auc` и `val_AUC` на каждой эпохе обучения. Для своевременного предотвращения переобучения при первых его признаках активируется встроенный механизм ранней остановки `EarlyStopping`.

Заключительным этапом методологии является расчет расширенного набора метрик на изолированной тестовой выборке. На данном шаге оцениваются такие параметры качества, как Precision, Recall, F1-score и F2-score. Дополнительно проводится обязательная проверка вклада отдельных клинических признаков в итоговый результат.

3 Описание метода решения

3.1 Архитектурные принципы

Разделение входных данных

Для обеспечения объективности выводов весь массив данных разбивается на три независимые выборки обучающую 70%, валидационную 15% и тестовую 15%. Учитывая наличие дисбаланса, применяется метод стратификации, который сохраняет исходное соотношение классов примерно 14% больных диабетом к 86% здоровых в каждом из подмножеств, что необходимо для предотвращения переобучения модели на доминирующем классе и корректной оценки её обобщающей способности.

Обработка дисбаланса классов

Методы синтетической генерации данных, такие как SMOTE, могут вносить шум в клиническую картину. Поэтому в данной работе реализован подход взвешивания классов. Система автоматически увеличивает штраф за ошибку на объектах меньшего класса в процессе минимизации функции потерь. При этом нейросеть уделяет больше внимания признакам больных пациентов, не искажая при этом реальную плотность распределения признаков в наборе данных.

Нормализация признаков

Нейронные сети крайне чувствительны к масштабу входных данных. Для обеспечения сходимости градиентного спуска применяется StandardScaler, который приводит все числовые признаки к единому размеру со средним значением 0 и дисперсией 1. Такой подход исключает ситуацию, когда признаки с большими абсолютными значениями, например, уровень дохода или возраст подавляют менее масштабные, но клинически значимые показатели.

Архитектура с регуляризацией

В ходе автоматического поиска с помощью библиотеки KerasTuner будет определена оптимальная топология сети с максимальным количеством нейронов на одном слое 256 и с максимальным количеством слоев равным 4.

Для стабилизации обучения используется пакетная нормализация BatchNormalization, а для борьбы с заучиванием данных применяется Dropout с долей исключения нейронов до 0.5.

Интерпретируемость через SHAP

Для преодоления проблемы «черного ящика» в модель интегрирован модуль интерпретации на основе библиотеки SHAP. Использование теории кооперативных игр позволяет математически точно оценить вклад каждого клинического фактора в итоговый риск заболевания для конкретного пациента. Это обеспечивает прозрачность принятия решений, необходимую для внедрения системы в реальную клиническую практику.

3.2 Ожидаемые результаты

Формулировка ожидаемых результатов работы базируется на необходимости достижения компромисса между математической строгостью нейросетевых моделей и требованиями современной медицины. В отличие от общецелевых задач классификации, проектируемая система должна учитывать специфику сильно несбалансированных клинических данных доля положительного класса 14%.

На основе анализа существующих аналогов и предварительных запусков алгоритмов автоматического подбора архитектуры KerasTuner определены следующие целевые показатели эффективности:

1. В рамках исследования ожидается достижение устойчивого показателя ROC-AUC и PR-AUC на уровне не менее 0.83, что соответствует высокой разделяющей способности модели при обработке многомерных данных. Но, учитывая социальную значимость пропуска больных пациентов, приоритетным критерием эффективности так же выступает полнота Recall для класса «Диабет». За счет реализации модуля математической оптимизации подбора порога отсечения по метрике F2-score ожидается выявление не менее 80% реально больных пациентов из тестовой выборки. Допускаемое при этом разумное снижение точности Precision до уровня 30 процентов признается

приемлемым для систем первичного скрининга, задачей которых является отбор потенциальных пациентов для последующей диагностики и лечения под наблюдением.

2. Ожидается, что в процессе автоматизированного поиска будет сформирована четырехслойная архитектура глубокой нейронной сети с нелинейным расширением признакового пространства до 256 нейронов в скрытом слое. Также, что использование слоев Batch Normalization и регуляризации Dropout с коэффициентом 0.5 позволит минимизировать риск переобучения на доминирующем классе и обеспечит стабильную работу модели на новых, ранее ненаблюдавшихся табличных данных.

3. Важным результатом работы является преодоление проблемы «черного ящика» нейронной сети. Ожидается получение верифицируемых SHAP-значений для каждого прогноза. Это позволяет визуализировать иерархию влияния признаков, где такие параметры как общее состояние здоровья GenHlth, возраст и индекс массы тела BMI будут иметь превалирующее значение, что согласуется с общими принципами медицины. Обосновывать каждый вердикт о высоком риске заболевания конкретными отклонениями в профиле пациента.

4. Разработанная программа должна обеспечивать высокую скорость обработки данных для возможности интеграции в информационные системы медицинских учреждений. Ожидаемое время генерации индивидуального прогноза в модуле `predict_patient.py` должно составлять разумное время, а общий цикл обучения модели на массиве данных объемом более 250 000 записей не должен превышать несколько часов на стандартных вычислительных мощностях.

4 Реализация метода решения

4.1 Автоматизированный подбор параметров нейронной сети

Поскольку жесткое определение количества скрытых слоев и размерностей матриц похоже на угадывание, в работе была использована библиотека KerasTuner с алгоритмом Hyperband. Этот алгоритм использует метод многорукого бандита и последовательное уполовинивание Successive Halving для быстрого тестирования сотен конфигураций, отсекая неудачные архитектуры на ранних эпохах

Пространство поиска включало:

1. Количество слоев: от 1 до 4.
2. Размерность слоя: от 32 до 256 нейронов.
3. Наличие слоя Batch Normalization: True / False.
4. Доля исключения Dropout rate: от 0.1 до 0.5.
5. Скорость обучения Learning Rate: 0.01, 0.001.

В рамках исследования были проведены два независимых цикла нахождения наиболее подходящей модели. Первый с целью максимизации val_AUC ROC-AUC, а второй с целью максимизации val_pr_auc PR-AUC. В условиях дисбаланса классов метрика PR-AUC является более чувствительной к качеству распознавания класса больных.

Результаты первого цикла оптимизации по метрике PR-AUC с начальной скоростью обучения 0.01 завершил тестирование за 38 минут, выявив наиболее подходящую архитектуру. Топология нейронной сети включила в себя 3 скрытых слоя:

Dense (128 нейронов) -> BatchNormalization (True) -> Dropout (0.3)

Dense (224 нейрона) -> BatchNormalization (False) -> Dropout (0.5)

Dense (160 нейронов) -> BatchNormalization (True) -> Dropout (0.1)

Выходной слой Dense (1)

Эти данные можно посмотреть на рис. 1.

```

Trial 90 Complete [00h 01m 53s]
val_pr_auc: 0.4231078624725342

Best val_pr_auc So Far: 0.42958471179008484
Total elapsed time: 00h 38m 13s

```

=== ВЫБРАННЫЕ ГИПЕРПАРАМЕТРЫ ===

```

num_layers: 3
units_0: 128
batch_norm_0: True
dropout_0: 0.30000000000000004
learning_rate: 0.01
units_1: 224
batch_norm_1: False
dropout_1: 0.5
units_2: 160
batch_norm_2: True
dropout_2: 0.1
units_3: 256
batch_norm_3: False
dropout_3: 0.4
tuner/epochs: 50
tuner/initial_epoch: 17
tuner/bracket: 2
tuner/round: 2
tuner/trial_id: 0068

```

=== АРХИТЕКТУРА ЛУЧШЕЙ НЕЙРОСЕТИ ===

Model: "sequential_1"

Layer (type)	Output Shape	Param #
dense_2 (Dense)	(None, 128)	2,816
batch_normalization_1 (BatchNormalization)	(None, 128)	512
dropout_1 (Dropout)	(None, 128)	0
dense_3 (Dense)	(None, 224)	28,896
dropout_2 (Dropout)	(None, 224)	0
dense_4 (Dense)	(None, 160)	36,000
batch_normalization_2 (BatchNormalization)	(None, 160)	640
dropout_3 (Dropout)	(None, 160)	0
dense_5 (Dense)	(None, 1)	161

Total params: 69,025 (269.63 KB)

Trainable params: 68,449 (267.38 KB)

Рисунок 1 – Подбор параметров PR-AUC

Также результаты второго цикла оптимизации по метрике ROC-AUC с начальной скоростью обучения 0.01 завершил тестирование за 33 минуты,

выявив наиболее подходящую архитектуру. Топология нейронной сети включила в себя 3 скрытых слоя, причем каждый следующий уменьшается в 2 раза:

Dense (256 нейронов) -> BatchNormalization (False) -> Dropout (0.1)

Dense (128 нейронов) -> BatchNormalization (False) -> Dropout (0.2)

Dense (64 нейрона) -> BatchNormalization (True) -> Dropout (0.5)

Выходной слой Dense (1)

Эти данные можно посмотреть на рис. 2.

```

Trial 90 Complete [00h 00m 51s]
val_AUC: 0.8285784125328064

Best val_AUC So Far: 0.8293710350990295
Total elapsed time: 00h 33m 10s

=== ВЫБРАННЫЕ ГИПЕРПАРАМЕТРЫ ===
num_layers: 3
units_0: 256
batch_norm_0: False
dropout_0: 0.1
learning_rate: 0.01
units_1: 128
batch_norm_1: False
dropout_1: 0.2
units_2: 64
batch_norm_2: True
dropout_2: 0.5
units_3: 32
batch_norm_3: False
dropout_3: 0.5
tuner/epochs: 17
tuner/initial_epoch: 6
tuner/bracket: 2
tuner/round: 1
tuner/trial_id: 0058

=== АРХИТЕКТУРА ЛУЧШЕЙ НЕЙРОСЕТИ ===
Model: "sequential_1"

```

Layer (type)	Output Shape	Param #
dense_5 (Dense)	(None, 256)	5,632
dropout_4 (Dropout)	(None, 256)	0
dense_6 (Dense)	(None, 128)	32,896
dropout_5 (Dropout)	(None, 128)	0
dense_7 (Dense)	(None, 64)	8,256
batch_normalization (BatchNormalization)	(None, 64)	256
dropout_6 (Dropout)	(None, 64)	0
dense_8 (Dense)	(None, 1)	65

```

Total params: 47,105 (184.00 KB)
Trainable params: 46,977 (183.50 KB)
Non-trainable params: 128 (512.00 B)

```

Рисунок 2 – Подбор параметров AUC-ROC

4.2 Финальное обучение моделей

Две выбранные архитектуры были подвергнуты финальному обучению до 100 эпох с применением механизма ранней остановки Early Stopping, patience=10 и механизма динамического снижения скорости обучения ReduceLROnPlateau factor=0.2, patience=5. Использование минибатчей размером 512 примеров позволило эффективно использовать вычислительные ресурсы.

В результате валидационные метрики модели, поиск которой в автоматическом режим осуществлялся по метрике PR-AUC, достигли значения: AUC-ROC = 0.825, PR_AUC = 0.429, что видно из рис. 3.

```
Epoch 30/100
347/347 ————— 3s 10ms/step - AUC: 0.8332 - f2_score: 0.2749 - loss: 0.4984 - pr_auc:
0.4333 - recall: 0.8052 - val_AUC: 0.8294 - val_f2_score: 0.2756 - val_loss: 0.5122 - val_pr_auc:
0.4286 - val_recall: 0.8008 - learning_rate: 4.0000e-04 - val_custom_score: 0.8123

Epoch 31/100
347/347 ————— 3s 9ms/step - AUC: 0.8331 - f2_score: 0.2748 - loss: 0.4987 - pr_auc:
0.4334 - recall: 0.8026 - val_AUC: 0.8294 - val_f2_score: 0.2742 - val_loss: 0.5098 - val_pr_auc:
0.4287 - val_recall: 0.7982 - learning_rate: 4.0000e-04 - val_custom_score: 0.8107

Epoch 32/100
344/347 ————— 0s 8ms/step - AUC: 0.8370 - f2_score: 0.2731 - loss: 0.4938 - pr_auc:
0.4381 - recall: 0.8060

Epoch 32: ReduceLROnPlateau reducing learning rate to 7.999999215826393e-05.
347/347 ————— 3s 10ms/step - AUC: 0.8334 - f2_score: 0.2743 - loss: 0.4982 - pr_auc:
0.4331 - recall: 0.8045 - val_AUC: 0.8294 - val_f2_score: 0.2767 - val_loss: 0.5131 - val_pr_auc:
0.4289 - val_recall: 0.8025 - learning_rate: 4.0000e-04 - val_custom_score: 0.8133
```

Рисунок 3 – Обучение модели по PR-AUC

Во втором же случае метрики модели, поиск которой в автоматическом режим осуществлялся по метрике AUC-ROC, достигли значения: AUC-ROC = 0.829, PR_AUC = 0.429, что видно из рис. 4.

```

Epoch 20/100
347/347 ————— 2s 7ms/step - AUC: 0.8350 - f2_score: 0.2770 - loss: 0.4968 -
pr auc: 0.4354 - recall: 0.8129 - val AUC: 0.8288 - val_f2_score: 0.2746 - val_loss: 0.5104 -
val pr auc: 0.4295 - val_recall: 0.7993 - learning_rate: 0.0020 - val_custom_score: 0.8111

Epoch 21/100
343/347 ————— 0s 6ms/step - AUC: 0.8370 - f2_score: 0.2734 - loss: 0.4933 -
pr auc: 0.4425 - recall: 0.8088

Epoch 21: ReduceLROnPlateau reducing learning rate to 0.0003999999724328518.
347/347 ————— 2s 7ms/step - AUC: 0.8351 - f2_score: 0.2762 - loss: 0.4968 -
pr auc: 0.4367 - recall: 0.8119 - val AUC: 0.8288 - val_f2_score: 0.2724 - val_loss: 0.5000 -
val pr auc: 0.4287 - val_recall: 0.7939 - learning_rate: 0.0020 - val_custom_score: 0.8078

```

Рисунок 4 – Обучение модели по AUC-ROC

4.3 Подбор порога классификации

Как было обосновано в Главе 2, в медицине критически важно максимизировать выявление больных пациентов Recall, минимизируя ложноотрицательные ответы. Стандартный порог нейронной сети, при котором класс 1 назначается при $P \geq 0.5$, не является оптимальным. При стандартном пороге 0.5 модель, которая искалась по метрике PR-AUC продемонстрировала полноту Recall на уровне 0.79. Это означает, что 21% людей реальных больных диабетом классифицировались как здоровые. Для модели, которая искалась по метрике AUC-ROC значение полноты составило 0.84. Для исправления этой ситуации была написана программа для автоматической оптимизации порога `evaluate_model_pr_auc.py` и аналогичный `evaluate_model_auc_roc.py`.

Логика алгоритма оптимизации.

Нейронная сеть генерирует сырые вероятности `y_pred_probs` для всех пациентов из независимой тестовой выборки 15% данных.

Задается математический диапазон исследования порогов $t \in [0.01, 0.99]$ с шагом дискретизации 0.01.

В цикле для каждого значения t вероятности преобразуются в бинарные метки, если $p > t$, то предсказание = 1, иначе 0.

Для каждого вектора бинарных предсказаний вычисляется F_2 – score, использующий $\beta=2$ штраф за ложноотрицательный ответ в 2 раза выше.

Находится порог t_{opt} , при котором метрика F_2 достигает абсолютного максимума.

В результате работы программы было установлено, что для модели, которая искалась по метрике PR-AUC наиболее подходящий порог составил 0.46. Максимальный достижимый F_2 – score при данном пороге составил 0.610, что видно по рис. 5 и рис. 6.




Рисунок 5 – Зависимость метрики F2-score от порога классификации PR-AUC

```
(.venv) PS C:\dev_works\diplom\code\diabetes_binary_health_indicators_BRFSS2015> python .\evaluate_model_pr_auc.py
WARNING: All log messages before absl::InitializeLog() is called are written to STDERR
I0000 00:00:1778087807.657724 16068 port.cc:153] oneDNN custom operations are on. You may see slightly different numerical results due to
.
WARNING: All log messages before absl::InitializeLog() is called are written to STDERR
I0000 00:00:1778087809.422061 16068 port.cc:153] oneDNN custom operations are on. You may see slightly different numerical results due to
.
1. Подготовка тестовых данных...
2. Загрузка обработчиков и применение к тестовой выборке...
3. Загрузка сохраненной нейросети...
I0000 00:00:1778087810.308063 16068 cpu feature_guard.cc:227] This TensorFlow binary is optimized to use available CPU instructions in pe
To enable the following instructions: SSE3 SSE4.1 SSE4.2 AVX AVX2 FMA, in other operations, rebuild TensorFlow with the appropriate compile
WARNING:tensorflow:TensorFlow GPU support is not available on native windows for TensorFlow >= 2.11. Even if CUDA/cuDNN are installed, GPU
4. Выполнение предсказаний на тестовой выборке...
1190/1190 ██████████ 1s 698us/step

Поиск идеального порога для максимизации F2-score...
Идеальный порог: 0.46
Максимальный F2-score при этом пороге: 0.6104
График 'threshold_optimization_pr_auc.png' успешно сохранен!

=== ФИНАЛЬНЫЙ ОТЧЕТ О КЛАССИФИКАЦИИ (Порог 0.46) ===
      precision    recall  f1-score   support

Нет диабета      0.96      0.67      0.79     32750
    диабет      0.29      0.84      0.43      5302

 accuracy      0.70      0.70      0.70     38052
 macro avg      0.63      0.76      0.61     38052
weighted avg      0.87      0.70      0.74     38052
```

Рисунок 6 – Подбор порога PR-AUC

В результате работы второй программы было установлено, что для модели, которая искалась по метрике AUC-ROC наиболее подходящий порог составил 0.49. Максимальный достижимый F_2 – score при данном пороге составил 0.610, что видно по рис. 7 и рис. 8


```
(.venv) PS C:\dev_works\diplom\code\diabetes_binary_health_indicators_BRFSS2015> python .\evaluate_model_auc_roc.py
WARNING: All log messages before absl::InitializeLog() is called are written to STDERR
I0000 00:00:1778085002.936451 17328 port.cc:153] oneDNN custom operations are on. You may see slightly different numerical re
.
WARNING: All log messages before absl::InitializeLog() is called are written to STDERR
I0000 00:00:1778085004.663191 17328 port.cc:153] oneDNN custom operations are on. You may see slightly different numerical re
.
1. Подготовка тестовых данных...
2. Загрузка обработчиков и применение к тестовой выборке...
3. Загрузка сохраненной нейросети...
I0000 00:00:1778085005.512848 17328 cpu_feature_guard.cc:227] This TensorFlow binary is optimized to use available CPU instru
To enable the following instructions: SSE3 SSE4.1 SSE4.2 AVX AVX2 FMA, in other operations, rebuild TensorFlow with the appropri
WARNING:tensorflow:TensorFlow GPU support is not available on native Windows for TensorFlow >= 2.11. Even if CUDA/cuDNN are ins
4. Выполнение предсказаний на тестовой выборке...
1190/1190 ————— 1s 666us/step

Поиск идеального порога для максимизации F2-score...
Идеальный порог: 0.49
Максимальный F2-score при этом пороге: 0.6105
График 'threshold_optimization_auc_roc.png' успешно сохранен!

=== ФИНАЛЬНЫЙ ОТЧЕТ О КЛАССИФИКАЦИИ (Порог 0.49) ===
      precision    recall  f1-score   support

Нет диабета      0.96      0.67      0.79      32750
Диабет          0.29      0.84      0.43       5302

   accuracy      0.69      0.69      38052
  macro avg      0.63      0.75      0.61      38052
weighted avg      0.87      0.69      0.74      38052
```

Рисунок 7 – Зависимость метрики F2-score от порога классификации AUC-ROC




Рисунок 8 – Подбор порога AUC-ROC

Анализ кривой на графиках наглядно подтверждает наличие глобального максимума в точке 0.46 и 0.49 соответственно обозначено красной вертикальной пунктирной линией. При дальнейшем снижении порога F_2 падает из-за критического обрушения точности Precision.

4.4 Оценка производительности на тестовой выборке

Окончательное тестирование производительности было проведено в двух вариантах, сначала на нейронной сети, которая искалась по AUC-ROC, потом на той, что искалась по PR-AUC, на отложенной выборке в 38 052 пациента, которая не участвовала ни в одном из этапов оптимизации и градиентного спуска. Это позволяет гарантировать объективность полученных результатов.

Для нейронной сети, которая искалась по метрике PR-AUC, метрики составили: ROC-AUC 0.830, PR-AUC 0.426. Применение вычисленного оптимального порога 0.46 позволило сформировать финальный отчет о классификации, представленный в таблице 6.

Для второго варианта, когда нейронная сеть искалась по метрике AUC-ROC метрики составили ROC-AUC 0.830, PR-AUC 0.426. Применение вычисленного оптимального порога 0.49 позволило сформировать финальный отчет о классификации, представленный в таблице 5.

С данными результатами тестирования на тестовой выборке, проведенного мной в рамках исследования на тему «НЕЙРОННАЯ СЕТЬ ДЛЯ ПРОГНОЗИРОВАНИЯ РИСКА ЗАБОЛЕВАНИЙ НА ОСНОВЕ МНОГОМЕРНЫХ ДАННЫХ» можно ознакомиться на рис. 9 и на рис. 10.

Таблица 5 – отчет о классификации на тестовой выборке AUC-ROC

Класс пациентов	Precision (Точность)	Recall (Полнота)	F1-Score	Support (Кол-во)
0: нет диабета	0.96	0.72	0.82	32 750
1: Диабет	0.31	0.79	0.45	5 302

Продолжение таблицы 5

Macro Avg	0.63	0.75	0.63	38 052
Weighted Avg	0.87	0.73	0.77	38 052

Таблица 6 – отчет о классификации на тестовой выборке AUC-ROC

Класс пациентов	Precision (Точность)	Recall (Полнота)	F1-Score	Support (Кол-во)
0: нет диабета	0.96	0.67	0.79	32 750
1: Диабет	0.29	0.84	0.43	5 302
Macro Avg	0.63	0.76	0.61	38 052
Weighted Avg	0.87	0.70	0.74	38 052

```

Лучшая модель успешно обучена и сохранена!

=== ОЦЕНКА НА ТЕСТОВОЙ ВЫБОРКЕ ===
1190/1190 ██████████ 1s 676us/step
ROC-AUC: 0.8296
PR-AUC: 0.4259
F2-Score: 0.6104

Отчет о классификации (Порог 0.5):
      precision    recall  f1-score   support

Нет диабета      0.96      0.67      0.79     32750
Диабет           0.29      0.84      0.43      5302

   accuracy              0.70     38052
  macro avg      0.63      0.76      0.61     38052
 weighted avg      0.87      0.70      0.74     38052

```

Рисунок 9 – Тестирование AUC-ROC

```
Лучшая модель успешно обучена и сохранена!

=== ОЦЕНКА НА ТЕСТОВОЙ ВЫБОРКЕ ===
1190/1190 ██████████ 1s 712us/step
ROC-AUC: 0.8304
PR-AUC: 0.4263
F2-Score: 0.6058

Отчет о классификации (Порог 0.5):
      precision    recall  f1-score   support

Нет диабета      0.96      0.72      0.82     32750
    Диабет      0.31      0.79      0.45      5302

   accuracy              0.73     38052
  macro avg      0.63      0.75      0.63     38052
weighted avg      0.87      0.73      0.77     38052
```

Рисунок 10 – Тестирование PR-AUC

Анализ результатов.

Смещение порога привело к клинически оправданному перераспределению ошибок. Для нейронной сети, которая искалась по метрике PR-AUC, полнота Recall для больных пациентов выросла до 84%. Это означает, что нейронная сеть успешно детектирует 84 из 100 пациентов с диабетом.

При этом точность прогнозирования нормы Precision для класса 0 составила 0.96, если алгоритм заявляет, что пациент здоров, вероятность ошибки составляет лишь 4%.

Снижение точности Precision для класса «Диабет» до 0.29 является закономерным результатом балансировки.

Для нейронной сети, которая же искалась по метрике AUC-ROC, полнота Recall для больных пациентов сохранилась и составила аналогичные 0.84. Это объясняется тем, что полученный после оптимизации порог составил 0.49 против изначальных 0.5.

На практике это означает, что на каждого реально больного пациента система выдаст несколько ложных тревог. В условиях первичного медицинского скрининга такая стратегия признается оптимальной. Алгоритм работает как чувствительный фильтр, направляющий потенциально больных в группу риска для последующей сдачи недорогих лабораторных анализов крови.

4.5 Интерпретация с помощью SHAP

Одной из ключевых преград на пути внедрения алгоритмов глубокого обучения в реальную клиническую практику является проблема «черного ящика» Модели обладают высокой предсказательной способностью, но механизмы принятия ими решений скрыты внутри сотен тысяч весов нелинейных матричных преобразований. Для преодоления проблемы прозрачности разработанных архитектур глубоких нейронных сетей и обеспечения проверяемости их предсказаний, в программный комплекс был интегрирован специализированный модуль интерпретируемости на основе фреймворка `shap.DeepExplainer`. Данный алгоритм базируется на классической теории кооперативных игр и вычисляет значения вектора Шепли, математически строго распределяя «выигрыш» между «игроками».

Для анализа логики обученных моделей были построены графики распределения значений. На рисунке 11 представлен график важности признаков для глубокой нейронной сети, оптимизация которой осуществлялась по метрике PR-AUC. На данном графике каждая точка отображает индивидуального пациента из тестовой выборки. Цветовая шкала показывает исходное значение конкретного клинического фактора. Ярко-красный цвет соответствует максимальному значению признака, а ярко-синий – минимальному. Смещение точки относительно центра по оси абсцисс демонстрирует насколько данный фактор увеличил или уменьшил конечную вероятность отношения пациента к классу «Диабет».

Анализ распределения SHAP-значений для модели PR-AUC рис. 11 полностью подтвердил клиническую адекватность и биологическую обоснованность нейронной сети. Факторами, оказывающими доминирующее влияние на выявление высокого риска заболевания, алгоритм признал индекс массы тела и оценку общего состояния здоровья пациента. На графике находится плотный кластер ярко-красных точек в правой части признака BMI, что доказывает, что избыточный вес и ожирение повышают риски развития диабета 2-го типа.

Значительный вклад в смещение прогноза в сторону положительного класса вносят такие факторы, как наличие артериальной гипертензии и возраст. Концентрация красных точек в правой зоне графика для данных параметров подтверждает, что наличие стабильно повышенного давления и высокий возраст пациента являются мощными стимуляторами заболевания. Фактор регулярной физической активности демонстрирует защитный эффект. Скопление красных точек сосредоточено в левой полуплоскости, что указывает на снижение итоговой вероятности заболевания за счет активного образа жизни.




Рисунок 11 – График важности признаков SHAP для нейросетевой модели PR-AUC

Для проведения сравнительного анализа логики принятия решений на рисунке 12 представлен аналогичный график важности признаков, но для второй архитектуры нейронной сети, которая оптимизировалась по метрике AUC-ROC. Сравнение двух полученных графиков рис. 11 и рис. 12 наглядно

демонстрирует, что результирующие структуры распределения важности факторов получились различными. Это явление напрямую обосновано тем, что в процессе автоматического поиска KerasTuner были сформированы принципиально разные топологии скрытых слоев нейронных сетей, которые в процессе градиентного спуска сориентировались на различные целевые функции. Так, в AUC-ROC модели (см. рис. 12) фактор возраста поднялся на вторую позицию по степени глобального влияния, хотя общий состав топ-факторов остался неизменным.

Практическая и клиническая значимость внедрения фреймворка SHAP заключается в обеспечении прозрачности и интерпретируемости сложных математических моделей для практикующих врачей. В рамках разрабатываемой системы для каждого индивидуального прогноза генерируется детальный локальный график.




Рисунок 12 – График важности признаков SHAP для нейросетевой модели AUC-ROC

Графики для разных моделей получились разными. Это обосновано тем, что структура нейронных сетей получилась разная и они по-разному считали важность признаков. Использование SHAP обеспечивает понимание врачей, позволяет формировать индивидуальные отчеты и предоставляет понятную

структуру важности факторов. В таких отчетах для каждого пациента детально может быть расписано, почему система назначила ему тот или иной риск.

5 Безопасность жизнедеятельности

Развитие информационных технологий требует особого внимания к вопросам безопасности труда и жизнедеятельности. БЖД - это наука, изучающая безопасное взаимодействие человека и окружающей среды, а также методы минимизации рисков возникновения травм и профессиональных заболеваний. В настоящее время при работе с персональным компьютером человек подвергается воздействию ряда вредных и опасных факторов, таких как статичная поза, нагрузка на зрение и нервно-эмоциональное напряжение. Длительная работа без соблюдения норм может привести к снижению зрения, заболеваниям опорно-двигательного аппарата и эмоциональному стрессу. Поэтому строгое соблюдение требований безопасности и организация режима труда и отдыха играют ключевую роль в сохранении здоровья сотрудника.

5.1 Общая характеристика условий применения

Выпускная работа бакалавра посвящена разработке нейронной модели для прогнозирования риска заболеваний на основе многомерных клинических данных.

Разработка программного обеспечения выполнялась в домашних условиях на персональном компьютере и на операционной системе Windows 11. Написание исходного кода происходило на языке программирования Python в среде разработки VS Code. Этот раздел посвящен анализу возможных опасностей, возникающих в процессе создания ПО и вопросам обеспечения безопасности нейросетевой модели, так как она является одним из элементов информационных медицинских систем.

5.2 Анализ опасностей

При разработке программного обеспечения на ПК, в соответствии с ГОСТ 12.0.003-2015, на разработчика воздействуют опасные и вредные производственные факторы. В процессе выполнения данной работы можно выделить следующие основные факторы:

Физические факторы: повышенный уровень электромагнитных излучений от монитора, плохие параметры микроклимата в помещении, такие как температура и влажность, а также недостаточная освещенность рабочего пространства [13].

Психофизиологические факторы: статические физические перегрузки, связанные с длительным поддержанием рабочего положения за монитором сидя на кресла, перенапряжение глаз при работе с монитором, умственное перенапряжение и монотонность труда при написании данной работы [13].

Для оценки потенциально опасного воздействия разрабатываемого программного средства ПС необходимо провести его классификацию. В соответствии с ГОСТ Р ИСО/МЭК ТО 12182–2002 «Информационная технология. Классификация программных средств», классификация разработанной модели представлена в таблице 7 [14].

Таблица 7 – Классификация программного средства

Вид	Класс
Функция ПС	Медицинские системы, научные вычисления
Режим эксплуатации	Пакетная обработка данных
Масштаб ПС	Малый
Критичность ПС	Человеческая жизнь
Требование надежности	Высокая отказоустойчивость, высокая завершенность
Вычислительная система и среда	Персональный компьютер (Windows)
Исходный язык	Объектно-ориентированный (Python)

Так как разрабатываемое программное обеспечение предназначено для оценки риска заболеваний, отдельной категорией опасности является риск постановки ложноотрицательного прогноза, что означает пропуск больного пациента. Данная ошибка алгоритма в медицине может привести к позднему оказанию медицинской помощи. Значит, кроме защиты здоровья разработчика, необходимо обеспечить безопасность эксплуатации самого алгоритма нейронной сети.

5.3 Обеспечение допустимого риска разработки

Обеспечение безопасных условий труда при разработке программы и снижение рисков от воздействия физических и психофизиологических факторов достигается соблюдением действующих нормативных требований.

Защита от вредных факторов среды и организация рабочего места при выполнении работ сидя регламентируются СанПиН 1.2.3685–21.

Микроклимат в помещении не менее важен чем остальные факторы. Работа за компьютером относится к категории легких физических работ, категория Ia. Оптимальная температура воздуха в помещении в холодный период года должна составлять 22-24 °С, в теплый – 23-25 °С при относительной влажности 40-60 % [15].

Для предотвращения перенапряжения глаз и негативных последствий рабочее место должно иметь достаточное естественное и искусственное освещение. При общем искусственном освещении уровень освещенности на рабочей поверхности должен составлять не менее 400 лк, а коэффициент пульсации – не более 5 % [15].

Факторы звукового давления строго нормируются. Работа выполнялась в домашних условиях, поэтому применяются нормативы для жилых комнат. В дневное время эквивалентный уровень звука не должен превышать 40 дБА, а максимальный 55 дБА. Для профессиональных рабочих мест, требующих постоянного интеллектуального труда и высокой сосредоточенности, эквивалентный уровень звука допускается на уровне не более 50 дБА.

Снижение психофизиологических нагрузок. Для минимизации статических нагрузок на позвоночник необходимо использовать правильное рабочее кресло с регулировкой высоты сиденья и угла наклона спинки. Для снятия нервного и зрительного напряжения рекомендуется соблюдать режим труда и отдыха, делая перерывы на 10–15 минут каждый час работы за компьютером [15].

Для проверки соответствия персонального рабочего места данным требованиям было проведено исследование с использованием мобильных приложений-анализаторов (шумомер).

Микроклимат: Фактическая температура в помещении составляет 23 °С, влажность 45 %, что полностью укладывается в нормы СанПиН. Для поддержания этих параметров производилось регулярное проветривание помещения.

Эксперимент с освещенностью не был проведен, так как отсутствует возможность измерить освещенность на рабочей поверхности и коэффициент пульсации.

Шум: Уровень шума от системного блока компьютера составил 35 дБА. Этот уровень находится в пределах нормы для жилых помещений.

Снижение психофизиологических нагрузок: Для минимизации статических нагрузок на позвоночник используется эргономичное кресло с регулировкой высоты. Соблюдается режим труда и отдыха: каждый час работы за компьютером делается перерыв на 15 минут

Безопасность ПО - это минимизация риска перехода системы в опасное состояние в результате ошибок классификации. Разрабатываемое ПО должно соответствовать критериям безопасности для систем искусственного интеллекта в клинической медицине [16].

В рамках данной ВКР допустимый риск разработки обеспечивается следующими методами:

Снижение ложноотрицательных итогов: применение алгоритма динамического нахождения порога классификации с оптимизацией по метрике F2-score. Порог был сдвинут с 0.5 до 0.46 для PR-AUC модели и с 0.5 до 0.49 для AUC-ROC модели, что позволило повысить полноту Recall обнаружения больных до 84 %, что гарантирует, что система минимизирует риск пропуска больных пациентов с диабетом.

Интерпретируемость или устранение «черного ящика»: использование нейронных сетей в медицине часто ограничено из-за их непонимания людьми или даже другими программами. Для обеспечения доверия к результатам и безопасности принимаемых на их основе решений в архитектуру внедрен алгоритм SHAP. Алгоритм позволяет математически обосновать каждый прогноз, четко показывая, какие именно клинически важные факторы, например, высокий индекс массы тела, возраст, уровень жизни, привели к данному формированию вывода о высоком риске заболевания человека диабетом.

Разрабатываемое ПО предназначено для оценки риска заболеваний на основе многомерных клинических данных и должно соответствовать жестким критериям безопасности для систем искусственного интеллекта в клинической медицине [17].

Функциональные возможности (пригодность). Способность алгоритма решать заявленные медицинские задачи и обеспечивать безопасность принимаемых решений. В данной работе это достигается снижением ложноотрицательных итогов за счет применения алгоритма динамического нахождения порога классификации с оптимизацией по метрике F2-score. Порог был сдвинут с 0.5 до 0.46 для PR-AUC модели и с 0.5 до 0.49 для AUC-ROC модели. Это позволило повысить полноту (Recall) обнаружения больных до 84 %, минимизируя риск пропуска пациентов с диабетом.

Практичность (понятность для пользователя). Свойство, определяющее удобство и прозрачность работы алгоритма для конечного пользователя. Использование нейронных сетей в медицине часто ограничено из-за эффекта черного ящика, поэтому для обеспечения доверия специалистов используется алгоритм SHAP. Он обеспечивает интерпретируемость каждого прогноза, четко показывая, какие именно клинически важные факторы, например, высокий индекс массы тела, возраст, уровень жизни, повлияли на формирование вывода.

Надежность. Способность программного средства сохранять свой уровень работоспособности в заданных условиях. Разработанная модель имеет малый масштаб, но относится к критическому классу, потому что она влияет на человеческую жизнь, и обладает высокой отказоустойчивостью и завершенностью при обработке больших объемов многомерных данных.

Эффективность. Оптимальное соотношение уровня услуг, предоставляемых ПО, и объема используемых ресурсов. Программная реализация нейросетевой модели адаптирована для работы на стандартном персональном компьютере (вычислительная система Windows), обеспечивая высокую скорость прогнозирования без избыточной нагрузки на оперативную память и процессор.

Сопровождаемость. Способность ПО к модификации, исправлению ошибок или адаптации к изменениям среды. Написание исходного кода происходило на высокоуровневом объектно-ориентированном языке программирования Python в среде разработки VS Code, что обеспечивает хорошую структурированность и читаемость кода. Это позволяет легко дообучать нейросеть на новых медицинских данных или изменять параметры модели в будущем.

Мобильность. Способность программы быть перенесенной из одной среды в другую. Благодаря использованию кроссплатформенного языка Python, разработанная модель не привязана к одной операционной системе или

компьютеру и может быть интегрирована в любые другие операционные системы или более сложные медицинские системы.

ЗАКЛЮЧЕНИЕ

В рамках выполнения выпускной квалификационной работы была успешно спроектирована, реализована и исследована архитектура глубокой нейронной сети для оценки риска развития диабета по табличным данным датасета BRFSS 2015.

Проведен детальный обзор существующих подходов и аналогов, представляющих основные парадигмы современного машинного обучения в медицине (GBDT, DNN, LSTM, трансформеры и гибридные ансамбли). Анализ показал, что полносвязные нейронные сети (DNN) достигают высокой точности классификации, сопоставимой с градиентным бустингом, однако требуют внимательного решения проблемы дисбаланса классов, глубокой регуляризации, применения внешних техник интерпретируемости.

Спроектирована многослойная архитектура глубокой полносвязной нейронной сети для оценки риска развития диабета по многомерным табличным данным анкетного скрининга BRFSS 2015. В структуре решения учтена специфика медицинских данных. Внедрен модуль предобработки со стандартизацией и восстановлением пропусков, реализован метод стратификации выборок, а также применено алгоритмическое взвешивание классов (`class_weight='balanced'`), что позволило эффективно обучить модель без искусственного и шумового искажения реальных данных.

Реализован программный модуль автоматизированного подбора гиперпараметров на базе библиотеки KerasTuner с использованием алгоритма Hyperband. Были проведены два независимых цикла оптимизации по метрикам AUC-ROC и PR-AUC, в ходе которых протестированы сотни конфигураций. Финальное обучение архитектур до 100 эпох с механизмами EarlyStopping позволило получить устойчивую модель, показавшую высокое значение ROC-AUC (0.830) на независимой отложенной тестовой выборке из 38052 пациентов.

Разработан и реализован алгоритм динамического смещения порога классификации, максимизирующий метрику F_2 – *score*. За счет двукратного

повышения штрафа за ложноотрицательный ответ. Математический порог принятия решений 0.5 был смещен до значения 0.46 (для PR-AUC модели) и 0.49 (для AUC-ROC модели). Это позволило поднять чувствительность обнаружения целевого заболевания до 84% и минимизировать риски пропуска больных пациентов.

Интегрирована система объяснения решений на основе библиотеки SHAP, полностью устранившая проблему «черного ящика» нейронной сети. Сформированные глобальные и локальные графики важности факторов подтвердили адекватность модели и ее соответствие общим принципам медицины. Ключевыми триггерами риска признаны индекс массы тела (BMI), общее восприятие здоровья (GenHlth), гипертония (HighBP) и преклонный возраст (Age), однако физическая активность (PhysActivity) показала выраженный защитный эффект.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

[1] Мишкин И.А., Концевая А.В., Сахаров А.А. и др. Возможности оценки сердечно-сосудистого риска с применением искусственного интеллекта без использования предикторов, нуждающихся в инвазивных методах определения. Эффективная фармакотерапия. 2025; 21(8):8–14. DOI: 10.33978/2307-3586-2025-21-8-8-14. URL: <https://umedp.ru/upload/iblock/a2f/Mishkin.pdf> (дата обращения: 10.12.2025)

[2] Zhang H., Li X., Zhang S. Modeling health risks using neural network ensembles. Springer Journal of Medical Systems. 2024. URL: <https://link.springer.com/article/10.1007/s10916-024-02000-0> (дата обращения: 10.12.2025)

[3] Sharma M., Cohen J. Application of artificial intelligence in medical risk prediction. Sage Open Medicine. 2024. URL: <https://journals.sagepub.com/doi/10.1177/20552076251380652> (дата обращения: 17.12.2025)

[4] Ivanov I.I., Petrov A.A., Sidorov V.V. и др. Optimized neural network-based methods for coronary heart disease risk prediction. Nature Scientific Reports. 2025; 15:85765. URL: <https://www.nature.com/articles/s41598-025-85765-x> (дата обращения: 10.12.2025)

[5] Rotmensch M., Halpern Y., Elhadad N. Neural Networks for Survival Prediction in Medicine Using Prognostic Factors. PLOS ONE. 2022. URL: <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0308922> (дата обращения: 10.12.2025)

[6] Zhang H., Li X., Zhang S. Multi-disease prediction using LSTM recurrent neural networks. Expert Systems with Applications. 2021; 175:114841. URL:

<https://www.sciencedirect.com/science/article/pii/S0957417421003468>

(дата обращения: 10.12.2025)

[7] Che Z., Purushotham S., Cho K., Sontag D. Recurrent Neural Networks for Time Series Forecasting: Current Status and Future Directions. Journal of Machine Learning Research. 2018. URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC5606055/> (дата обращения: 10.12.2025)

[8] Machine Learning Explainability in Breast Cancer Survival using LIME and SHAP. Nature Scientific Reports. 2023; 13:10097. URL: <https://www.nature.com/articles/s41598-023-35795-0> (дата обращения: 10.12.2025)

[9] Interpreting Artificial Intelligence Models: A systematic review on the application of LIME and SHAP in Alzheimer's disease detection. Diagnostics. 2024; 14(4):401. URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC10997568/> (дата обращения: 16.12.2025)

[10] Explainable AI in Healthcare: A Stacking-Based Approach for Diabetes Classification. IEEE Transactions on Biomedical Engineering. 2025. URL: <https://ieeexplore.ieee.org/document/11009637> (дата обращения: 16.12.2025)

[11] Yerbese M., Ozkaya U., Sekeroglu B. et al. SAINT: Improved Neural Networks for Tabular Data via Row Attention and Contrastive Pre-Training. arXiv. 2021. URL: <https://arxiv.org/abs/2106.01342> (дата обращения: 17.12.2025)

[12] Huang X., Khetan A., Cvitkovic M., Karnin Z. TabTransformer: Tabular Data Modeling Using Contextual Embeddings. arXiv. 2020. URL: <https://arxiv.org/pdf/2012.06678.pdf> (дата обращения: 17.12.2025)

[13] ГОСТ 12.0.003-2015

[14] ГОСТ Р ИСО/МЭК ТО 12182–2002

[15] СанПиН 1.2.3685–21

[16] ГОСТ Р 59921.1-2022

[17] ГОСТ ИСО/МЭК 9126-2001