

НЕЙРОННАЯ СЕТЬ ДЛЯ ПРОГНОЗИРОВАНИЯ РИСКА ЗАБОЛЕВАНИЙ НА ОСНОВЕ МНОГОМЕРНЫХ ДАННЫХ

Выполнил:

Мордасов Евгений Дмитриевич, гр. 2383

Руководитель:

Борисенко Константин Алексеевич, к.т.н., доцент

Актуальность работы.

Актуальность: своевременное прогнозирование заболевания позволяет снизить нагрузку на систему здравоохранения, уменьшить расходы, дает больше времени на исследование болезни

Ручная проверка:

- занимает слишком много времени
- требует квалифицированных работников

Цель и задачи

Цель: разработать нейросетевую модель для прогнозирования риска заболеваний на основе многомерных клинических данных.

Задачи:

1. Обзор существующих подходов и аналогов
2. Спроектировать архитектуру глубокой нейронной сети
3. Реализовать модуль обучения и автоматического подбора гиперпараметров
4. Разработать алгоритм подбора порога классификации
5. Использовать систему объяснения решений SHAP

Задача 1

Метод	Точность (AUC)	Обработка данных	Интерпретируемость
GBDT (XGBoost/Cat Boost)	Высокая (2)	Высокая (2)	Средняя (1)
DNN / MLP	Средняя (1)	Средняя (1)	Средняя (1)
LSTM (Рекуррентные)	Низкая (0)	Низкая (0)	Средняя (1)
Предложенный (DNN+SHAP)	Высокая (2)	Средняя (1)	Высокая (2)

Задача 2

- **Модуль предобработки:** StandardScaler и алгоритмическое взвешивание классов (Class Weight).
- **Классификатор:** Глубокая сеть (до 4 слоев) с функциями ReLU и Batch Normalization.
- **Оптимизатор:** Механизмы Dropout (0.5) для борьбы с переобучением.
- **Модуль SHAP:** Генерация локальных и глобальных объяснений прогноза.




Рисунок 1. Пример DNN


Задача 3

Использование KerasTuner Hyperband для нахождения параметров нейронной сети:

- Слои от 1 до 4 (выбрано 3).
- Нейроны 32 – 256 (выбрано 224 в скрытом слое).
- Скорость обучения 0.01 – 0.001.
- Метрика оптимизации PR-AUC.

Обучение

Обучение проводилось до 100 эпох с ранней остановкой, на рисунке 2 представлены полученные метрики



Задача 4




Рисунок 3. График порога

Максимизация метрики F2-score для снижения ложноотрицательных результатов:

$$F2 = \frac{5 \cdot \text{Precision} \cdot \text{Recall}}{4 \cdot \text{Precision} + \text{Recall}}$$

Оптимальный порог: 0.46 (сдвиг от 0.5).

Задача 5

GenHlth (Общее здоровье):
доминирующий фактор
влияния.

BMI (Индекс массы тела):
высокие значения резко
повышают риск.

PhysActivity: подтвержден
защитный эффект
физической активности.




Рисунок 4. Значения SHAP

SHAP value (impact on model output)

Тестирование

Тестирование проведено на независимой выборке из 38052 пациентов.

Метрика	Значение (Порог 0.46)	Интерпретация
Recall (Полнота)	84%	Выявление 84 из 100 больных
Precision (Здоровые)	96%	Ошибка в норме лишь в 4% случаев
ROC-AUC	0.83	Высокая разделяющая способность
Время прогноза	< 100 мс	Работа в реальном времени

Заключение

- Проведен сравнительный анализ и обоснован выбор полносвязной нейронной сети в связке с методами интерпретируемости для работы с медицинскими данными.
- Спроектирована четырехслойная архитектура глубокой нейронной сети
- Реализован модуль автоматического подбора гиперпараметров, обеспечивший достижение показателя ROC-AUC на уровне 0.83
- Разработан алгоритм калибровки порога классификации по метрике F2-score, что повысило полноту до 84%.
- Интегрирован модуль SHAP с наглядной визуализацией вклада каждого симптома в итоговый риск.

Направления дальнейших исследований: расширение спектра входных параметров, проведение на обезличенных данных локальных медицинских учреждений для проверки её стабильности вне рамок исходного датасета.

Апробация работы

- Репозиторий проекта <https://github.com/Pryflas/diplom>