

Санкт-Петербургский государственный электротехнический университет им. В.И.
Ульянова (Ленина)

НЕЙРОННАЯ СЕТЬ ДЛЯ ПРОГНОЗИРОВАНИЯ РИСКА ЗАБОЛЕВАНИЙ НА ОСНОВЕ МНОГОМЕРНЫХ ДАННЫХ

Выполнил:
Руководитель:

Мордасов Евгений Дмитриевич, гр. 2383
Борисенко Константин Алексеевич., к.т.н., доцент

Санкт-Петербург, 2026

Цель и задачи

Актуальность: Раннее и точное прогнозирование риска заболеваний позволяет своевременно организовать профилактические мероприятия. Современные методы на основе нейронных сетей демонстрируют высокую точность и адаптивность при работе с многомерными медицинскими. Нейросетевые подходы показывают потенциал в повышении точности прогнозирования, что делает их актуальными для внедрения в системы поддержки принятия врачебных решений.

Цель: разработать нейросетевую модель для прогнозирования риска заболеваний на основе многомерных клинических данных, обеспечивающую AUC-ROC не менее 90%.

Задачи:

1. Выполнить обзор нейросетевых и ML-методов прогнозирования риска заболеваний.
2. Спроектировать архитектуру нейросети с учётом особенностей многомерных данных.
3. Обучить модель, подобрать гиперпараметры, провести оценку по метрикам (AUC-ROC, точность, полнота, F1).
4. Сравнить полученную модель с классическими алгоритмами (логистическая регрессия, деревья решений, бустинг) и проанализировать результаты.
5. Исследовать интерпретируемость модели с помощью SHAP.

Постановка задачи

- ПРОБЛЕМА: Разработать интерпретируемую нейросетевую систему, достигающую одновременно высокую точность И объяснимость
- ДАННЫЕ: Табличные медицинские данные (40 признаков) с дисбалансом классов (~70% здоровых, ~30% больных)
- ТРЕБОВАНИЯ: $AUC-ROC \geq 0.90$ И клинически обоснованные объяснения через SHAP-значения

Анализ архитектур

- Сравнены 5 парадигм ML по 3 критериям: точность (AUC-ROC), обработка табличных данных, интерпретируемость
- GBDT (XGBoost/CatBoost): Лидер по встроенной обработке данных (баллы 2,2,1), но требует SHAP для объяснений
- DNN: Сравнимая точность (1,1,1), требует кодирования признаков, SMOTE и class_weights
- LSTM: Низкая эффективность на статических данных (0,0,1), так как временная структура отсутствует
- GBDT+SHAP/LIME: ЛУЧШИЙ БАЛАНС (2,2,2) — высокая точность + критическая интерпретируемость
- Трансформеры: Перспективны, но менее зрелы, требуют GPU и больше данных (1,1,2)
- ВЫВОД: Гибридные ансамбли с SHAP обеспечивают оптимальный баланс для клинического применения

Выбор и обоснование метода решения

- Выбрана: Гибридная архитектура (DNN + SHAP для интерпретируемости)
- Компонента 1 – Предварительная обработка:
StandardScaler (нормализация) → Label Encoding (категории) → Mean/Mode Imputation (пропуски) → SMOTE (дисбаланс)
- Компонента 2 – Нейросетевой классификатор (MLP):
Input(40) → Dense(128,ReLU)+BatchNorm+Dropout(0.3) → Dense(64,ReLU)+BatchNorm+Dropout(0.3) → Dense(32,ReLU)+Dropout(0.3) → Dense(1,Sigmoid)
- Компонента 3 – Интерпретируемость:
SHAP для глобальных объяснений (вклад признаков) и локальных (конкретный пациент)

Архитектурные принципы

1. Разделение: 70% обучение, 15% валидация, 15% тестирование со стратификацией по целевой переменной
2. SMOTE только на обучении: Синтез примеров меньшинства (`sampling_strategy=0.7`) без утечки в валидацию
3. Нормализация (StandardScaler): К среднему 0, дисперсии 1, что критично для сходимости DNN
4. Регуляризация: Чередование Dropout(0.3) и Batch Normalization → предотвращает переобучение
5. SHAP для интерпретируемости: Теория кооперативных игр → вклад каждого признака в предсказание
 - Методология валидации:
Early stopping (10 эпох без улучшения) и Мониторинг AUC-ROC, Accuracy, Precision, Recall, F1
 - Параллельное обучение CatBoost как бенчмарка (часто AUC 0.92–0.95 на сырых данных)

Заключение и результаты

Задача 1: Проведён анализ 5 парадигм ML → выявлены ограничения, утверждены критерии

Задача 2: GBDT демонстрируют лучший профиль, но гибридные ансамбли GBDT+SHAP дают оптимальный баланс

Задача 3: Спроектирована гибридная архитектура (3-слойная DNN + SHAP) обеспечивающая $AUC-ROC \geq 0.90$ И интерпретируемость

Спасибо за внимание! Готов к вопросам.